

# Test Statistiques Descriptives - Test 2

**Sujet:** Statistiques Descriptives

**Niveau:** Intermédiaire

**Nombre de questions:** 25

---

## Questions et Réponses

**Q1.** Quelle est la différence entre population et échantillon?

**R1.** | | Population | Échantillon | |-----|-----| | **Définition** | Ensemble complet | Sous-ensemble | | **Notation moyenne** |  $\mu$  (mu) |  $\bar{x}$  (x-bar) | | **Notation écart-type** |  $\sigma$  (sigma) |  $s$  | | **Diviseur variance** |  $N$  |  $n-1$  | | **Exemple** | Tous les clients | 1000 clients sélectionnés |

---

**Q2.** Comment calculer la moyenne géométrique et quand l'utiliser?

**R2. Formule:**

$$G = \sqrt[n]{x \times x \times \dots \times x} = (x)^{(1/n)}$$

**En Python:**

```
from scipy.stats import gmean
geo_mean = gmean(data)
# ou
geo_mean = np.exp(np.mean(np.log(data)))
```

**Utilisation:** - Taux de croissance (returns) - Ratios - Données multiplicatives - Indices

---

**Q3.** Qu'est-ce que la moyenne harmonique et quand l'utiliser?

**R3. Formule:**

$$H = n / \sum(1/x)$$

**En Python:**

```
from scipy.stats import hmean
harm_mean = hmean(data)
```

**Utilisation:** - Moyennes de ratios (vitesses, taux) - Prix moyens pour quantités égales - F-score en ML

**Propriété:**  $G^2 = A \times H$  (Moyenne arithmétique  $\times$  harmonique)

---

**Q4.** Ordonnez: moyenne arithmétique, géométrique, harmonique pour des données positives.

**R4.** Pour des données positives non égales:

Harmonique   Géométrique   Arithmétique  
H   G   A

**Égalité uniquement si** toutes les valeurs sont identiques.

---

**Q5.** Calculez la moyenne, médiane et mode pour une distribution groupée:

Classe	Fréquence
0-20	5
20-40	12
40-60	18
60-80	10
80-100	5

**R5. Moyenne (avec milieux de classe):**

$$\bar{x} = \Sigma(f \times m) / \Sigma f$$

$$\bar{x} = (5 \times 10 + 12 \times 30 + 18 \times 50 + 10 \times 70 + 5 \times 90) / 50$$

$$\bar{x} = (50 + 360 + 900 + 700 + 450) / 50$$

$$\bar{x} = 2460 / 50 = 49.2$$

**Mode:** Classe modale = 40-60 (fréquence max = 18)

**Médiane:** Position = 50/2 = 25ème valeur → dans classe 40-60

---

**Q6.** Comment calculer l'écart-type pour des données groupées?

**R6. Formule:**

$$s = \sqrt{[\Sigma f (m - \bar{x})^2 / (n-1)]}$$

**En Python:**

*# Avec les milieux de classe*

```
midpoints = [10, 30, 50, 70, 90]
```

```
frequencies = [5, 12, 18, 10, 5]
```

*# Reconstruire les données*

```
data = np.repeat(midpoints, frequencies)
```

```
std = np.std(data, ddof=1)
```

---

**Q7.** Qu'est-ce que le Z-score et comment l'interpréter?

**R7. Formule:**

$$z = (x - ) / \quad \text{ou} \quad z = (x - \bar{x}) / s$$

**Interprétation:** - z = 0: Valeur égale à la moyenne - z = 1: 1 écart-type au-dessus de la moyenne - z = -2: 2 écarts-types en dessous

**Applications:** - Comparer des scores de différentes échelles - Détecter les outliers ( $|z| > 3$ ) - Standardisation pour ML

---

**Q8.** Comment les percentiles sont-ils utilisés dans l'analyse de risque bancaire?

**R8. Applications:** 1. **Scoring crédit:** Segmentation par percentiles de score 2. **VaR (Value at Risk):** P5 ou P1 des pertes 3. **Concentration:** Top 10% des expositions 4. **Benchmark:** Comparer un client à sa distribution

**Exemple:**

```
# VaR 95%
var_95 = np.percentile(losses, 95)

# Seuil top 10% clients
top_10_threshold = df['revenu'].quantile(0.90)
```

---

**Q9.** Quelle est la différence entre variance et écart-type en termes d'interprétation?

**R9.** | Variance ( $s^2$ ) | Écart-type ( $s$ ) | |-----|-----| | Unités au carré | Mêmes unités que les données | | Interprétation difficile | Interprétation directe | | Utile pour calculs | Utile pour communication | | Additif pour variables indép. | Non additif |

**Exemple:** Si montant en HTG → variance en HTG<sup>2</sup>, écart-type en HTG.

---

**Q10.** Comment calculer la médiane pour un nombre pair et impair d'observations?

**R10. Nombre impair (n):**

Médiane = valeur à la position  $(n+1)/2$

**Nombre pair (n):**

Médiane =  $(\text{valeur à } n/2 + \text{valeur à } n/2+1) / 2$

**Exemple:** - [3, 5, 7, 9, 11] →  $n=5$  → position 3 → médiane = 7 - [3, 5, 7, 9] →  $n=4$  → moyenne de positions 2 et 3 →  $(5+7)/2 = 6$

---

**Q11.** Qu'est-ce que la mesure de dispersion MAD (Median Absolute Deviation)?

**R11. Formule:**

$MAD = \text{median}(|x - \text{median}(x)|)$

**En Python:**

```
from scipy.stats import median_abs_deviation
mad = median_abs_deviation(data)
```

**Avantages:** - Très robuste aux outliers - Point de rupture = 50% (vs 0% pour écart-type) - Relation avec  $\sigma$ :  $\sigma \approx 1.4826 \times MAD$  (pour distribution normale)

---

**Q12.** Comment interpréter un coefficient de variation de 150%?

**R12.** Un CV de 150% signifie: - L'écart-type est **1.5 fois la moyenne** - **Variabilité extrême** des données - Probablement présence d'**outliers** ou distribution très asymétrique - La moyenne n'est **pas représentative**

**Action recommandée:** - Utiliser la médiane et l'IQR - Investiguer les valeurs extrêmes - Considérer une transformation ou segmentation

---

**Q13.** Comment calculer et interpréter le coefficient de Gini pour mesurer l'inégalité?

**R13. Formule (simplifiée):**

$Gini = \Sigma |x - \bar{x}| / (2n^2)$

**Interprétation:** - 0 = Égalité parfaite - 1 = Inégalité maximale

**Application bancaire:** Concentration du portefeuille

```
def gini_coefficient(x):  
    x = np.sort(x)  
    n = len(x)  
    index = np.arange(1, n+1)  
    return (2 * np.sum(index * x) - (n+1) * np.sum(x)) / (n * np.sum(x))
```

---

**Q14.** Comment les moments statistiques sont-ils liés aux mesures descriptives?

**R14.** | Moment | Ordre | Mesure | |---|---|---| | **1er moment centré** | 1 | Toujours 0 | | **2ème moment centré** | 2 | Variance | | **3ème moment standardisé** | 3 | Skewness | | **4ème moment standardisé** | 4 | Kurtosis |

**Formule générale du moment centré:**

$$m = \sum (x - \bar{x})^m / n$$

---

**Q15.** Qu'est-ce que la moyenne tronquée (trimmed mean)?

**R15.** La **moyenne tronquée** ignore un pourcentage des valeurs extrêmes.

```
from scipy.stats import trim_mean  
  
# Tronquer 10% de chaque côté  
trimmed = trim_mean(data, proportiontocut=0.1)
```

**Avantages:** - Robuste aux outliers - Conserve plus d'information que la médiane - Bon compromis entre moyenne et médiane

---

**Q16.** Comment calculer les déciles et les utiliser pour la segmentation client?

**R16.**

```
# Déciles  
deciles = np.percentile(df['montant'], np.arange(10, 100, 10))  
  
# Segmentation en déciles  
df['decile'] = pd.qcut(df['montant'], q=10, labels=range(1, 11))  
  
# Analyse par décile  
df.groupby('decile').agg({  
    'montant': ['mean', 'sum'],  
    'client_id': 'count'  
})
```

**Application:** Analyse Pareto - "Les 10% des clients les plus importants génèrent X% du volume"

---

**Q17.** Comment mesurer la symétrie d'une distribution avec le coefficient de Pearson?

**R17. Coefficient de skewness de Pearson:**

$$Sk = 3(\text{Moyenne} - \text{Médiane}) / \text{Écart-type}$$

**Interprétation:** -  $Sk_p \approx 0$ : Symétrique -  $Sk_p > 0$ : Asymétrie positive -  $Sk_p < 0$ : Asymétrie négative

**Avantage:** Facile à calculer avec les statistiques de base.

---

**Q18.** Comment analyser une distribution bimodale?

**R18.** Une distribution bimodale a deux pics distincts.

**Analyse:** 1. **Identifier la cause:** Mélange de deux populations? 2. **Segmenter:** Analyser chaque groupe séparément 3. **Statistiques par segment:**

```
# Clustering pour identifier les groupes
from sklearn.cluster import KMeans
kmeans = KMeans(n_clusters=2)
df['cluster'] = kmeans.fit_predict(df[['variable']])

# Stats par cluster
df.groupby('cluster')['variable'].describe()
```

---

**Q19.** Comment créer un tableau croisé avec des pourcentages en ligne, colonne et total?

**R19.**

```
# Tableau de base
ct = pd.crosstab(df['region'], df['produit'])

# Pourcentages en ligne
ct_row = pd.crosstab(df['region'], df['produit'], normalize='index') * 100

# Pourcentages en colonne
ct_col = pd.crosstab(df['region'], df['produit'], normalize='columns') * 100

# Pourcentages du total
ct_all = pd.crosstab(df['region'], df['produit'], normalize='all') * 100

# Avec marges
ct_margins = pd.crosstab(df['region'], df['produit'], margins=True)
```

---

**Q20.** Comment calculer les statistiques descriptives pour plusieurs variables simultanément?

**R20.**

```
# describe() pour toutes les variables
df.describe() # numériques par défaut
df.describe(include='all') # toutes

# Statistiques personnalisées
df.agg(['count', 'mean', 'std', 'min', 'max', 'skew'])

# Fonction personnalisée
def custom_stats(series):
    return pd.Series({
        'n': len(series),
        'mean': series.mean(),
```

```

        'median': series.median(),
        'std': series.std(),
        'cv': series.std() / series.mean() * 100,
        'skew': series.skew(),
        'kurt': series.kurtosis()
    })

df.select_dtypes(include=[np.number]).apply(custom_stats)

```

---

**Q21.** Comment comparer les statistiques entre deux groupes?

**R21.**

```

# Comparaison côte à côte
comparaison = df.groupby('groupe').agg({
    'montant': ['mean', 'median', 'std'],
    'age': ['mean', 'median', 'std']
})

# Différence
stats_g1 = df[df['groupe'] == 'A']['montant'].describe()
stats_g2 = df[df['groupe'] == 'B']['montant'].describe()
diff = stats_g1 - stats_g2

# Ratio
ratio = stats_g1 / stats_g2

```

---

**Q22.** Comment interpréter un box plot avec des outliers?

**R22.**

```

*           ← Outlier (> Q3 + 1.5×IQR)
|
           ← Maximum (sans outliers)

           ← Q3 (75ème percentile)
           ← Médiane (Q2)
           ← Q1 (25ème percentile)

           ← Minimum (sans outliers)
|
*           ← Outlier (< Q1 - 1.5×IQR)

```

**La boîte contient 50% des données (IQR)**

---

**Q23.** Quelle est la différence entre corrélation de Pearson et de Spearman?

**R23.** | Pearson | Spearman | |———|———| | Relations **linéaires** | Relations **monotones** | | Sensible aux outliers | Robuste aux outliers | | Données continues | Données ordinales acceptées | | Basé sur valeurs | Basé sur **rangs** |

```
# Pearson
pearson_corr = df['x'].corr(df['y'], method='pearson')

# Spearman
spearman_corr = df['x'].corr(df['y'], method='spearman')
```

**Q24.** Comment résumer les statistiques pour un rapport exécutif?

**R24. Format recommandé:**

Métrique	Valeur	Interprétation
N	10,000	Taille de l'échantillon
Moyenne	85,000 HTG	Tendance centrale
Médiane	52,000 HTG	Valeur typique
Écart-type	95,000 HTG	Dispersion
Min - Max	1K - 2M HTG	Étendue
P25 - P75	20K - 100K HTG	Plage centrale

**Message clé:** "Le montant médian est de 52K HTG avec une forte variabilité (CV=112%), suggérant des segments clients distincts."

**Q25.** Analysez et interprétez le tableau suivant pour deux agences:

Statistique	Agence A	Agence B
N clients	5,000	2,000
Montant moyen	100K	120K
Montant médian	95K	60K
Écart-type	40K	150K
Skewness	0.3	2.5

**R25. Analyse:**

**Agence A:** - Distribution quasi-symétrique (skew=0.3, moyenne≈médiane) - Variabilité modérée (CV=40%) - Clientèle homogène

**Agence B:** - Distribution très asymétrique (skew=2.5, moyenne » médiane) - Variabilité extrême (CV=125%) - Présence de quelques très gros clients - Médiane plus représentative (60K vs 120K)

**Recommandations:** - Agence A: Utiliser la moyenne pour le reporting - Agence B: Utiliser la médiane, investiguer les gros clients - Segmenter Agence B pour comprendre les deux populations

## Scoring

Score	Niveau
0-10	À améliorer

Score	Niveau
11-17	Intermédiaire
18-22	Avancé
23-25	Expert