

Test Statistiques Inférentielles - Test 1

Sujet: Enquêtes et Tests d'Hypothèses

Niveau: Intermédiaire

Nombre de questions: 25

Questions et Réponses

Q1. Quelle est la différence entre statistique descriptive et statistique inférentielle?

R1. | Descriptive | Inférentielle | -----|-----| | **Décrit** les données | **Généralise** à une population | | Résume un échantillon | Tire des conclusions | | Pas d'incertitude | Quantifie l'incertitude | | Moyenne, écart-type | Tests, intervalles de confiance |

Q2. Qu'est-ce qu'une hypothèse nulle (H_0) et alternative (H_1)?

R2. - H_0 (**Hypothèse nulle**): Affirmation de "pas d'effet" ou "pas de différence". C'est ce qu'on cherche à rejeter. - H_1 (**Hypothèse alternative**): Ce qu'on veut démontrer.

Exemple: - H_0 : Le taux de défaut = 5% (pas de changement) - H_1 : Le taux de défaut \neq 5% (changement)

Q3. Qu'est-ce que la p-value et comment l'interpréter?

R3. La **p-value** est la probabilité d'obtenir un résultat aussi extrême (ou plus) que celui observé, **si H_0 est vraie**.

Interprétation: - $p < \alpha \rightarrow$ Rejeter H_0 (résultat statistiquement significatif) - $p \geq \alpha \rightarrow$ Ne pas rejeter H_0

Attention: - p-value N'EST PAS la probabilité que H_0 soit vraie - Seuil classique: $\alpha = 0.05$ (5%)

Q4. Quelle est la différence entre erreur de Type I et Type II?

R4. | | H_0 vraie | H_0 fausse | |-|-|-----| | **Rejeter H_0** | **Type I (α)** Faux positif | Correct ✓ | | **Ne pas rejeter H_0** | Correct ✓ | **Type II (β)** Faux négatif |

Exemples bancaires: - Type I: Refuser un bon client (faux positif de risque) - Type II: Accepter un mauvais client (faux négatif de risque)

Q5. Qu'est-ce que la puissance d'un test?

R5. Puissance = 1 - β

La probabilité de rejeter H_0 quand elle est effectivement fausse (détecter un vrai effet).

Facteurs qui augmentent la puissance: - Augmenter la taille d'échantillon (n) - Augmenter α (mais augmente aussi Type I) - Effet plus grand - Réduire la variabilité

Standard: Puissance $\geq 80\%$

Q6. Comment calculer un intervalle de confiance pour une moyenne?

R6. Formule ($n > 30$ ou σ connu):

$$IC = \bar{x} \pm z \times (s/\sqrt{n})$$

Pour 95%: $z = 1.96$ **Pour 99%:** $z = 2.576$

Exemple: $\bar{x} = 100$, $s = 20$, $n = 100$ $IC\ 95\% = 100 \pm 1.96 \times (20/10) = 100 \pm 3.92 = [96.08, 103.92]$

```
from scipy import stats
confidence = 0.95
mean = df['montant'].mean()
se = stats.sem(df['montant'])
ci = stats.t.interval(confidence, len(df)-1, loc=mean, scale=se)
```

Q7. Quand utiliser un test z vs un test t?

R7. | Test z | Test t | |----|----| | σ population **connu** | σ population **inconnu** | | n **grand** (>30) | n **petit** (<30) | | Distribution normale | Distribution normale |

En pratique: Test t presque toujours (σ rarement connu).

Q8. Expliquez le test t pour comparer deux moyennes indépendantes.

R8. Hypothèses: - $H_0: \mu_1 = \mu_2$ (pas de différence) - $H_1: \mu_1 \neq \mu_2$ (différence)

```
from scipy.stats import ttest_ind

# Test t (variances égales assumées)
t_stat, p_value = ttest_ind(group1, group2)

# Test Welch (variances inégales)
t_stat, p_value = ttest_ind(group1, group2, equal_var=False)

if p_value < 0.05:
    print("Différence significative")
```

Q9. Qu'est-ce qu'un test apparié (paired t-test)?

R9. Utilisé quand les **mêmes sujets** sont mesurés deux fois (avant/après).

Exemple: Satisfaction client avant et après une formation.

```
from scipy.stats import ttest_rel
```

```
# Test apparié
t_stat, p_value = ttest_rel(before, after)
```

Hypothèses: - $H_0: \mu_{\text{différence}} = 0$ - $H_1: \mu_{\text{différence}} \neq 0$

Q10. Quand utiliser l'ANOVA (Analysis of Variance)?

R10. Pour comparer les moyennes de **3 groupes ou plus**.

Exemple: Comparer les montants moyens entre 4 agences.

```

from scipy.stats import f_oneway

# ANOVA
f_stat, p_value = f_oneway(agence1, agence2, agence3, agence4)

```

Si $p < 0.05$: Au moins une moyenne diffère. **Ensuite:** Tests post-hoc (Tukey) pour identifier lesquelles.

Q11. Qu'est-ce que le test du Chi-carré et quand l'utiliser?

R11. Test pour **variables catégorielles**.

Types: 1. **Test d'indépendance:** Deux variables sont-elles liées? 2. **Test d'ajustement:** La distribution correspond-elle à un modèle?

```

from scipy.stats import chi2_contingency

# Tableau de contingence
contingency = pd.crosstab(df['secteur'], df['defaut'])

# Test Chi-carré
chi2, p_value, dof, expected = chi2_contingency(contingency)

```

Q12. Comment interpréter le résultat d'un test Chi-carré?

R12. Exemple de résultat: - $\text{Chi}^2 = 15.3$ - $df = 4$ - $p\text{-value} = 0.004$

Interprétation: - $p < 0.05 \rightarrow$ Les variables sont **significativement associées** - Le secteur et le défaut ne sont pas indépendants - Certains secteurs ont des taux de défaut différents

Q13. Quelle est la différence entre test unilatéral et bilatéral?

R13. | Bilatéral | Unilatéral | |-----|-----| | $H_1: \mu \neq \mu_0$ | $H_1: \mu > \mu_0$ ou $\mu < \mu_0$ | | Différence dans n'importe quel sens | Direction spécifique | | p-value complète | p-value / 2 | | Plus conservateur | Plus puissant si direction connue |

Règle: Utiliser bilatéral sauf si direction clairement justifiée.

Q14. Comment calculer la taille d'échantillon nécessaire?

R14. Pour estimer une proportion:

$$n = (z^2 \times p \times (1-p)) / e^2$$

Exemple: Estimer taux de défaut avec précision 2% - $z = 1.96$ (95% confiance) - $p = 0.05$ (estimation) - $e = 0.02$ (marge d'erreur)

$$n = (1.96^2 \times 0.05 \times 0.95) / 0.02^2 = \mathbf{457 \text{ clients minimum}}$$

```

from statsmodels.stats.power import zt_ind_solve_power
n = zt_ind_solve_power(effect_size=0.5, alpha=0.05, power=0.8)

```

Q15. Qu'est-ce que le théorème central limite (TCL)?

R15. Énoncé: Quelle que soit la distribution de la population, la distribution des moyennes d'échantillons tend vers une normale quand n est grand.

Implications: - Permet d'utiliser les tests z/t même si les données ne sont pas normales - Seuil pratique: $n \geq 30$ - Plus l'échantillon est grand, meilleure est l'approximation

Q16. Comment vérifier la normalité des données?

R16. Tests statistiques:

```
from scipy.stats import shapiro, normaltest

# Shapiro-Wilk (n < 5000)
stat, p = shapiro(data)

# D'Agostino-Pearson
stat, p = normaltest(data)
```

Méthodes visuelles: - QQ-plot - Histogramme avec courbe normale

Si $p > 0.05$: Distribution approximativement normale.

Q17. Quand utiliser les tests non-paramétriques?

R17. Utiliser quand: - Données non-normales - Échantillon petit - Données ordinaires - Présence d'outliers

Test Paramétrique	Équivalent Non-Paramétrique
t-test indépendant	Mann-Whitney U
t-test apparié	Wilcoxon signé
ANOVA	Kruskal-Wallis

Q18. Comment interpréter un intervalle de confiance?

R18. IC 95% = [45%, 55%] pour un taux de défaut.

Interprétation correcte: "Si on répétait l'échantillonnage 100 fois, 95 des intervalles contiendraient la vraie valeur."

Interprétation pratique: "On est confiant à 95% que le vrai taux est entre 45% et 55%."

INCORRECT: "Il y a 95% de chances que le vrai taux soit dans cet intervalle."

Q19. Qu'est-ce que la correction de Bonferroni pour les tests multiples?

R19. Quand on fait plusieurs tests, le risque d'erreur Type I augmente.

Correction:

$\alpha_{\text{ajusté}} = \alpha / k$

Exemple: 5 tests avec $\alpha = 0.05$ $\alpha_{\text{ajusté}} = 0.05 / 5 = 0.01$

Utiliser pour chaque comparaison individuelle.

Q20. Comment conduire un test de proportion?

R20. Hypothèses: - $H_0: p = p_0$ - $H_1: p \neq p_0$

```

from statsmodels.stats.proportion import proportions_ztest

# Données
successes = 48 # Ex: 48 défauts
n = 1000 # sur 1000 prêts
p0 = 0.05 # proportion attendue

# Test
z_stat, p_value = proportions_ztest(successes, n, p0)

```

Q21. Comment comparer deux proportions?

R21. Exemple: Comparer taux de défaut entre deux agences.

```

from statsmodels.stats.proportion import test_proportions_2indep

# Données
count1, n1 = 45, 1000 # Agence A: 45 défauts sur 1000
count2, n2 = 60, 1200 # Agence B: 60 défauts sur 1200

# Test
z_stat, p_value = test_proportions_2indep(
    count1, n1, count2, n2, compare='diff'
)

```

Q22. Qu'est-ce que la taille d'effet et pourquoi est-elle importante?

R22. La **taille d'effet** mesure l'importance pratique d'un résultat (vs significativité statistique).

Cohen's d (différence de moyennes):

$$d = (\bar{X}_1 - \bar{X}_2) / s_{\text{pooled}}$$

Interprétation: - $d < 0.2$: Effet faible - $0.2 < d < 0.8$: Effet modéré - $d > 0.8$: Effet fort

Importance: Un résultat peut être statistiquement significatif mais pratiquement négligeable.

Q23. Comment conduire un A/B test pour une campagne marketing bancaire?

R23. Étapes: 1. **Hypothèse:** $H_0: \text{Conversion_A} = \text{Conversion_B}$ 2. **Randomisation:** Assigner aléatoirement les clients 3. **Taille échantillon:** Calculer n nécessaire 4. **Exécution:** Collecter les données 5. **Analyse:**

```

# Données A/B test
conversions_A, n_A = 120, 1000
conversions_B, n_B = 150, 1000

# Test de proportion
from statsmodels.stats.proportion import test_proportions_2indep
z, p = test_proportions_2indep(conversions_A, n_A, conversions_B, n_B)

# Intervalle de confiance pour la différence
diff = conversions_B/n_B - conversions_A/n_A

```

Q24. Quelles sont les conditions d'application d'un test t?

R24. Conditions: 1. **Indépendance:** Observations indépendantes 2. **Normalité:** Distribution normale (ou $n > 30$) 3. **Homogénéité des variances:** Pour test à deux échantillons (sinon Welch)

Vérification:

```
# Normalité
from scipy.stats import shapiro
shapiro(data)
```

```
# Homogénéité des variances
from scipy.stats import levene
levene(group1, group2)
```

Q25. Interprétez le résultat suivant: - Test: t-test comparant le score crédit moyen des clients en défaut vs non-défaut - $t = -8.45$ - $p\text{-value} = 0.0000001$ - Moyenne défaut: 520, Moyenne non-défaut: 680 - Cohen's $d = 1.2$

R25. Interprétation:

1. **Significativité:** $p < 0.001 \rightarrow$ Différence **hautement significative**
 2. **Direction:** t négatif \rightarrow Score moyen des défauts < Score non-défauts
 3. **Amplitude:**
 - Différence = 160 points ($680 - 520$)
 - Cohen's $d = 1.2 \rightarrow$ **Effet très fort**
 4. **Conclusion business:**
 - Le score de crédit est un **excellent discriminant** du risque
 - Les clients en défaut ont en moyenne 160 points de moins
 - Justifie l'utilisation du score dans le processus de décision
-

Scoring

Score	Niveau
0-10	À améliorer
11-17	Intermédiaire
18-22	Avancé
23-25	Expert