

INITIATION A LA FONCTION DE TRAVAIL

Le contexte de travail d'un spécialiste de solutions de données

L'organisation : Un moteur alimenté par la donnée

2

- Une organisation n'est pas qu'un nom ou un logo ; c'est un ensemble structuré de ressources travaillant vers un objectif commun.
- 1. Les composantes essentielles :
 - ▣ Ressources Humaines : Les experts (vous !), les décideurs et les utilisateurs qui donnent du sens à l'information.
 - ▣ Ressources Matérielles : Serveurs, centres de données (Data Centers), terminaux et infrastructures réseaux.
- 2. La mission : Transformer l'information en valeur
 - ▣ Pour remplir sa mission (qu'elle soit commerciale, sociale ou publique), l'organisation doit :
 - Collecter : Capter la donnée là où elle se trouve (ventes, capteurs, interactions).
 - Exploiter : Transformer ces données brutes en outils d'aide à la décision.
- 3. Le besoin de structures technologiques
 - ▣ La donnée est une matière première "volatile". Sans une structure technologique robuste (l'architecture que vous allez bâtir), elle ne peut pas être stockée, sécurisée ni analysée.

Types d'organisations

3

- Le spécialiste de solutions de données est un profil universel. Son expertise s'adapte aux missions spécifiques de chaque type de structure :
- 1. Entreprises Privées (PME et Grandes Corporations)
 - ▣ Objectif : Rentabilité et compétitivité.
 - ▣ Intervention : Optimisation des chaînes logistiques (stocks), personnalisation du marketing et analyse du comportement d'achat pour augmenter les ventes.
- 2. Administrations Publiques (Gouvernements et Villes)
 - ▣ Objectif : Efficacité des services et bien-être citoyen.
 - ▣ Intervention : Gestion des dossiers de santé, statistiques d'État (recensement), optimisation des transports en commun et transparence des données publiques (Open Data).

Types d'organisations

4

- Le spécialiste de solutions de données est un profil universel. Son expertise s'adapte aux missions spécifiques de chaque type de structure :
- 3. Jeunes Pousses (Startups)
 - ▣ Objectif : Innovation et croissance rapide.
 - ▣ Intervention : Création de produits "Data-Centric" (ex: une app de santé basée sur l'IA), mise en place d'architectures agiles et évolutives dès le premier jour.
- 4. Sociétés de Services en TI (Consultation)
 - ▣ Objectif : Expertise pointue et flexibilité.
 - ▣ Intervention : Mandats variés pour des clients externes. Le spécialiste agit comme un expert-conseil qui intervient pour résoudre des problèmes complexes sur des technologies spécifiques.

Le quotidien du spécialiste dans ces organisations

5

- Le spécialiste évolue dans un écosystème humain dynamique où la communication est la clé :
- 1. Intégration en Équipes Internes : Dans une structure permanente, le spécialiste est un partenaire stratégique :
 - ▣ Support aux décisions : Il fournit les données fiables qui permettent à la direction de trancher (ex: lancer un nouveau produit ou fermer un entrepôt).
 - ▣ Continuité : Il connaît l'historique des données de l'entreprise et assure leur évolution à long terme.
- 2. La Collaboration Interdisciplinaire : Le spécialiste est un "traducteur" qui fait le pont entre deux mondes :
 - ▣ Le Monde Métier (Business) : Comprendre les problèmes des ventes, des RH ou des finances (ex: "Pourquoi mon rapport de ventes est-il lent ?").
 - ▣ Le Monde Technique : Transformer ces problèmes en solutions (ex: optimiser une requête SQL ou changer l'architecture Cloud).
- 3. Les partenaires du quotidien : Le spécialiste interagit constamment avec :
 - ▣ Les utilisateurs finaux pour valider que la solution est simple à utiliser.
 - ▣ Les experts en cybersécurité pour valider que les flux sont étanches.
 - ▣ Les gestionnaires de projets pour respecter les délais et les budgets.

L'organisation orientée données (data-driven)

6

- La donnée est utilisée comme un actif stratégique pour piloter l'entreprise :
 - ▣ Collecte systématique : les informations sont captées à chaque étape du processus d'affaires.
 - ▣ Prise de décision factuelle : les choix s'appuient sur des analyses réelles plutôt que sur l'instinct.
 - ▣ Culture de la mesure : utilisation d'indicateurs de performance (KPI) pour valider les résultats.
- Le rôle du spécialiste dans ce contexte :
 - ▣ Mise en place d'outils : déploiement de bases de données (SQL, NoSQL) et de solutions infonuagiques.
 - ▣ Accessibilité : garantir que la bonne information arrive à la bonne personne au bon moment.

Bénéfices et valeur ajoutée des solutions de données

7

- L'intégration de solutions de données apporte des gains mesurables :
 - ▣ Gain d'efficacité : automatisation des tâches répétitives et réduction des erreurs humaines.
 - ▣ Meilleure connaissance client : personnalisation des services et anticipation des besoins.
 - ▣ Agilité opérationnelle : capacité à réagir rapidement aux changements du marché.
 - ▣ Conformité et sécurité : respect des réglementations et protection des informations sensibles.
- Le spécialiste assure la pérennité du système :
 - ▣ Évolution constante : adaptation des outils aux nouvelles technologies et à l'IA.
 - ▣ Qualité de l'information : garantie de données fiables, cohérentes et persistantes pour les utilisateurs.

De l'organisation aux experts de la donnée

8

- Les organisations ont des besoins, mais qui réalise concrètement les solutions ?
 - ▣ Un écosystème complexe : interaction constante entre les équipes techniques et les directions métiers.
 - ▣ Des expertises variées : collaboration entre analystes, architectes, scientifiques, spécialistes de solutions de données, développeurs, testeurs, ...
 - ▣ Des environnements modernes : utilisation de méthodes agiles, du DevOps et du travail hybride.
- Place à la pratique :
 - ▣ Comment ces concepts s'appliquent-ils concrètement sur le terrain ?
 - ▣ Activité "Chasse aux données" : exploration de scénarios réels selon le type d'organisation.



Activité : Chasse aux données

9

- Objectif : Identifier les besoins en données selon le type d'organisation.
- Consignes pour le travail en équipe :
 - ▣ Choisissez un type d'organisation (Entreprise privée, Administration publique ou Startup).
 - ▣ Nommez un exemple concret d'organisation dans ce secteur.
 - ▣ Identifiez trois types de données que cette organisation doit collecter.
 - ▣ Expliquez pourquoi ces données sont essentielles à leur mission (le besoin d'affaires).
- Livrable attendu :
 - ▣ Une courte présentation orale de 2 minutes par équipe.
 - ▣ Identification des outils technologiques potentiels pour gérer ces flux (ex: SQL, Cloud).



Exemple de livrable

10

- Organisation choisie :
 - ▣ Type : Jeune pousse (startup) spécialisée en livraison de repas à domicile.
- Données collectées :
 - ▣ Coordonnées GPS des livreurs en temps réel.
 - ▣ Historique des commandes et préférences alimentaires des clients.
 - ▣ État des stocks et temps de préparation des restaurants partenaires.
- Besoins d'affaires :
 - ▣ Optimisation des trajets pour réduire les délais de livraison.
 - ▣ Recommandations personnalisées pour augmenter le panier moyen.
 - ▣ Suivi de la performance pour assurer la qualité du service.
- Outils technologiques pressentis :
 - ▣ Base de données SQL pour les commandes et infonuagique (AWS ou Azure) pour le stockage.
 - ▣ Outil de visualisation (BI) pour suivre les indicateurs de performance (KPI).

Étapes de développement et mise en service

11

- Le développement d'une solution de données suit un cycle de vie structuré pour garantir la qualité :
 - ▣ Analyse des besoins : définition des objectifs d'affaires et des données nécessaires.
 - ▣ Conception : modélisation de la solution et choix de l'architecture (relationnelle, NoSQL, etc.).
 - ▣ Développement : création des bases de données, des flux ETL et des interfaces.
 - ▣ Tests : validation de la précision des données, de la sécurité et des performances.
 - ▣ Déploiement : mise en service de la solution dans l'environnement de production.
 - ▣ Maintenance et évolution : correction des erreurs et ajout de nouvelles fonctionnalités selon les besoins.
- Le spécialiste de solutions de données :
 - ▣ Participe activement à chaque phase du cycle.
 - ▣ Assure la transition fluide entre le développement technique et l'utilisation métier.

Étape 1 : Analyse des besoins (Le "Pourquoi")

12

- C'est la phase de découverte. Avant de toucher à un clavier, il faut comprendre le problème à résoudre :
 - ▣ L'objectif : Définir précisément ce que la solution doit accomplir et quelles données sont nécessaires pour y parvenir.
 - ▣ Formats de représentation : Les User Stories (US)
 - Format : "En tant que [Rôle], je veux [Action] afin de [Bénéfice]."
 - Exemple : "En tant que Directeur des ventes, je veux voir un rapport quotidien des produits en rupture de stock afin de passer des commandes de réapprovisionnement rapidement."
 - ▣ Les critères d'acceptation : Chaque besoin est accompagné de conditions de succès.
 - Les données doivent être mises à jour toutes les heures.
 - Le rapport doit être accessible sur mobile.
 - ▣ Livrable :
 - Le cahier des charges ou le backlog, qui contient l'ensemble des spécifications validées par le client.

Étape 1 : Format des User Stories

13

Créer un nouveau projet

En tant que administrateur de l'application Redmine

Je veux créer un nouveau projet

Afin de gérer et suivre les tâches et activités associées à ce projet

Ajouter une nouvelle adresse email

En tant que utilisateur de l'application Redmine

Je veux ajouter une nouvelle adresse email à mon compte

Afin de recevoir des notifications sur plusieurs adresses.


Étape 2 : Conception (Le "Plan")

14

- L'architecte de données et le spécialiste dessinent la solution. Pour que tout le monde comprenne la même chose, on utilise des langages de modélisation standardisés.
- 1. Pourquoi utiliser des langages formels ?
 - ▣ Éviter l'ambiguïté : Une flèche a une signification précise, pas juste "un lien".
 - ▣ Documentation durable : Permet à un nouveau collègue de comprendre le système en un coup d'œil.
 - ▣ Validation : Vérifier la logique avant de dépenser du temps en développement.
- 2. Les principaux langages de représentation
 - ▣ UML (Unified Modeling Language) : Pour modéliser les structures de données (diagrammes de classes) et les interactions.
 - ▣ BPMN (Business Process Model and Notation) : Pour cartographier les processus d'affaires et le flux de travail des données.
 - ▣ Modèle C4 : Pour représenter l'architecture logicielle à différents niveaux de détail (Contexte, Conteneurs, Composants, Code).
 - ▣ Dictionnaires de données : Définir le type, la longueur et la source de chaque champ.


Étape 2 : Exemple de diagramme UML

15




Étape 2 : Exemple de diagramme BPMN

16



Étape 2 : Exemple de diagramme C4

17




Container diagram for Internet Banking System

The container diagram for the Internet Banking System.
Last modified: Wednesday 02 May 2018 13:46 UTC

Étape 3 : Développement (La "Construction")

18

- C'est le moment où les plans de conception deviennent une réalité technique. Le spécialiste utilise des outils pour garantir que le travail est organisé et réversible.
 1. La gestion de versions avec Git : Le code ne reste pas sur un ordinateur personnel. On utilise Git (et des plateformes comme GitHub ou GitLab) pour :
 - Travailler en équipe : Plusieurs spécialistes peuvent coder sur le même projet sans écraser le travail des autres.
 - Historique : Pouvoir revenir en arrière si une modification cause une erreur.
 - Traçabilité : Savoir exactement qui a modifié quoi et pourquoi.



Étape 3 : Développement (La "Construction")

19

2. Le passage par les environnements : On ne développe jamais directement là où les utilisateurs travaillent. On utilise des environnements séparés :
 - DEV (Développement) : Le bac à sable du spécialiste pour coder et faire ses premières erreurs.
 - TEST / QA (Assurance Qualité) : Un espace pour tester la solution avec des données qui ressemblent à la réalité.
 - PRE-PROD (Pré-production / Staging) : C'est une copie conforme de l'environnement de production souvent utilisée pour les tests d'acceptation.
 - PROD (Production) : L'environnement final, sécurisé et stable, utilisé par l'entreprise.
3. La réalisation technique :
 - Écriture des scripts SQL pour créer les tables.
 - Configuration des outils d'orchestration pour automatiser les flux ETL.
 - Documentation technique intégrée au code (commentaires).

Étape 4 : Tests (L'Assurance Qualité)

20

- On ne se demande pas si la solution fonctionne, on prouve qu'elle est robuste. Le spécialiste suit une pyramide de tests pour couvrir tous les risques.
- ▣ Les types de tests techniques :
 - Tests Unitaires : Vérification d'une seule règle isolée (ex: Est-ce que le calcul de la taxe est correct pour un produit donné ?).
 - Tests d'Intégration : On vérifie que les différents morceaux communiquent bien (ex: Est-ce que l'extracteur de données arrive à écrire dans la base de destination sans erreur de connexion ?).
 - Tests de Charge (Performance) : On simule un volume massif de données ou d'utilisateurs pour voir si le système ralentit ou "plante".

Étape 4 : Tests (L'Assurance Qualité)

21

- ▣ La validation des données (Data Quality)
 - Tests de cohérence : S'assurer qu'on n'a pas de doublons ou de valeurs aberrantes (ex: un âge de 150 ans).
 - Tests de complétude : Vérifier que 100% des données sources sont bien arrivées à destination.
- ▣ Les tests d'acceptation (UAT - User Acceptance Testing)
 - C'est l'étape humaine : les utilisateurs finaux testent la solution en Pré-prod.
 - Ils valident que l'outil répond bien aux User Stories définies à l'étape 1.
- ▣ Règle d'or : Un bogue trouvé en test coûte 10 fois moins cher à réparer qu'un bogue trouvé par un client en production.

Étape 5 : Déploiement (La "Mise en service")

22

- Le déploiement est le moment où la solution devient officiellement un outil de travail.
- Ce n'est pas un simple "copier-coller", mais une opération orchestrée.
 - ▣ Le pipeline CI/CD (Intégration et Déploiement Continu) : Pour éviter les erreurs humaines, on utilise souvent l'automatisation.
 - Continuous Integration (CI) : Le code est testé automatiquement dès qu'il est modifié.
 - Continuous Deployment (CD) : Si les tests réussissent, le code est envoyé automatiquement vers les environnements de test ou de production.

Étape 5 : Déploiement (La "Mise en service")

23

▣ Stratégies de déploiement et Sécurité

- Migration de données : Transférer les données historiques vers la nouvelle structure sans perte ni corruption.
- Le "Go-Live" : Bascule officielle vers le nouveau système.
- Plan de Rollback (Retour en arrière) : Une étape critique. Si un problème majeur survient dans les premières minutes du déploiement en production, on doit être capable de revenir instantanément à la version précédente.

▣ Monitoring (Surveillance) : Dès que la solution est "en ligne", on installe des sondes pour surveiller :

- Le taux d'utilisation.
- Les erreurs système en temps réel.
- Les temps de réponse pour garantir une expérience fluide.

Étape 6 : Maintenance et Évolution (La "Vie")

24

- Une solution de données n'est jamais figée. Elle doit s'adapter aux nouveaux besoins de l'entreprise et aux évolutions technologiques.
- La gestion de la "Dette Technique" :
 - Définition : Ce sont les compromis faits durant le développement (pour aller plus vite) qui devront être corrigés plus tard.
 - Le rôle du spécialiste : Prévoir des moments de "refactorisation" (nettoyage du code) pour éviter que le système ne devienne trop complexe ou instable avec le temps.

Étape 6 : Maintenance et Évolution (La "Vie")

25

- 2. Maintenance Corrective vs Évolutive
 - ▣ Corrective : Réparer les bogues imprévus ou les pannes de serveurs (le "support").
 - ▣ Évolutive : Ajouter de nouvelles sources de données ou modifier les rapports parce que la stratégie de l'entreprise a changé.
- 3. L'Amélioration Continue (Agilité) : Le cycle repart souvent à l'étape 1.
 - ▣ On récolte les commentaires des utilisateurs.
 - ▣ On identifie de nouveaux besoins.
 - ▣ On planifie la prochaine version de la solution.

Les rôles clés d'un projet de données

26

- Un projet de données nécessite la collaboration de plusieurs experts :
 - ▣ Analyste de données : interprète les données pour répondre aux questions d'affaires.
 - ▣ Spécialiste de solutions de données : Conçoit, développe et maintient les systèmes qui collectent, transforment et transportent la donnée de manière fiable et sécurisée.
 - ▣ Scientifique des données (Data Scientist) : crée des modèles prédictifs et utilise l'IA.
 - ▣ Architecte de données : conçoit la structure globale et la stratégie de stockage.
 - ▣ Chef de projet : coordonne les équipes et assure le respect des délais.
- L'importance de la synergie :
 - ▣ Chaque rôle possède une expertise spécifique mais dépend des autres.
 - ▣ Le flux de travail va de la captation brute de l'information jusqu'à sa visualisation finale.

Les rôles et responsabilités dans un projet de données

27

- Chaque étape du cycle de vie mobilise des experts aux responsabilités distinctes:
 - ▣ Analyste de données : responsable de l'analyse des besoins et de l'interprétation des résultats.
 - ▣ Spécialiste de solutions de données : assure la conception technique, le développement et la mise en service.
 - ▣ Architecte de données : définit la structure globale, la gouvernance et la conformité du système.
 - ▣ Scientifique des données (Data Scientist) : extrait des connaissances complexes et développe des modèles d'IA.
 - ▣ Chef de projet : assure la coordination entre les équipes et le respect des objectifs.
- L'interaction technique et métier:
 - ▣ Les équipes techniques (spécialistes, architectes) collaborent étroitement avec les équipes métiers.
 - ▣ Cette synergie garantit que la solution répond parfaitement aux défis réels de l'organisation.

Outils et technologies du spécialiste

28

- Pour bâtir ces solutions, le spécialiste utilise un coffre à outils diversifié :
 - ▣ Bases de données : stockage structuré avec SQL (ex: PostgreSQL) ou flexible avec NoSQL (ex: MongoDB).
 - ▣ Solutions ETL : outils pour extraire, transformer et charger les données entre les systèmes.
 - ▣ Infonuagique (Cloud) : utilisation de plateformes comme AWS, Azure ou Google Cloud (GCP).
 - ▣ Plateformes BI et orchestration : outils pour visualiser les données (Power BI, Tableau) et automatiser les flux.
- L'évolution technologique :
 - ▣ Passage du stockage local vers des solutions infonuagiques évolutives.
 - ▣ Importance croissante de l'automatisation et de l'intégration de l'intelligence artificielle.



Jeu de rôle : Qui fait quoi ?

29

- Scénario de crise : Une boutique de vêtements en ligne reçoit des plaintes : Le système indique qu'un article est en stock, mais après l'achat, le client reçoit un courriel disant qu'il est épuisé.
- Travail en équipe (15 min) :
 - Le Moment : À quelle étape du cycle de vie sommes-nous ? (Indice : la boutique est déjà ouverte aux clients).
 - L'Enquêteur : Qui, entre l'Analyste et le Spécialiste, va d'abord parler au gérant pour comprendre ce qui manque dans le rapport ?
 - Le Réparateur : Que doit vérifier le Spécialiste de solutions de données ?
 - La Sécurité : Si on répare le système, quelle règle d'éthique doit-on respecter concernant les infos des clients qui ont acheté ?



Jeu de rôle : Corrigé

30

□ Les 4 éléments :

- Le Moment (étape) : La Maintenance. Le système existe, mais il y a une erreur entre la réalité (l'entrepôt) et l'affichage (le site).
- L'Enquêteur : L'Analyste. Il doit définir l'écart : « Qu'est-ce qui est faux exactement ? ».
- Le Réparateur (Spécialiste en solutions de données) : Il vérifie le "voyage" de la donnée (ETL). Il s'assure que la mise à jour de l'inventaire se fait en temps réel et non une fois par jour.
- La Sécurité : Le spécialiste ne doit accéder qu'aux données nécessaires à la réparation (ex: quantités en stock) et ne jamais copier, consulter ou manipuler les renseignements personnels des clients (noms, adresses, cartes de crédit) sans autorisation ou nécessité technique absolue.

Environnements et méthodes de travail

31

- Le spécialiste évolue dans un cadre structuré et collaboratif :
 - ▣ Gestion de projet agile : utilisation de cycles de travail courts (sprints) pour s'adapter aux changements.
 - ▣ DevOps : intégration continue entre le développement de la solution et son exploitation technique.
 - ▣ Collaboration interdisciplinaire : échanges fréquents entre les experts techniques et les utilisateurs métiers.
- Modes de travail actuels :
 - ▣ Travail hybride : flexibilité entre le travail au bureau et le télétravail.
 - ▣ Outils de collaboration : utilisation de plateformes de communication et de partage de code en temps réel.
- Le rôle au quotidien :
 - ▣ Autonomie dans la réalisation des tâches techniques.
 - ▣ Participation active aux rencontres de coordination (daily meetings) pour lever les bloqueurs.

Conditions de travail et tendances du domaine

32

- La profession de spécialiste de solutions de données offre des perspectives solides :
 - ▣ Salaire et évolution : rémunération compétitive dès l'entrée sur le marché.
 - ▣ Perspectives de carrière : opportunités de spécialisation ou d'évolution vers des rôles d'architecte.
 - ▣ Formation continue : importance des certifications (AWS, Azure, GCP) pour rester à jour.
- Tendances actuelles et innovations :
 - ▣ Automatisation et IA : intégration croissante de l'intelligence artificielle dans les flux de données.
 - ▣ Gouvernance et éthique : responsabilité accrue dans la gestion de la confidentialité et de la protection des données.
 - ▣ Réglementation : respect des cadres légaux sur la vie privée et la sécurité des informations.
- L'avenir du métier :
 - ▣ Transition vers des systèmes toujours plus autonomes et intelligents.
 - ▣ Rôle central du spécialiste dans la transformation numérique des organisations.

Conclusion : Vers votre nouvelle carrière

33

- Points clés à retenir :
 - ▣ Un rôle pivot : le spécialiste est au cœur de l'écosystème, transformant les données brutes en solutions concrètes.
 - ▣ Un domaine en expansion : des besoins croissants dans tous les types d'organisations (privé, public, startup).
 - ▣ Une expertise technique et humaine : maîtrise des outils (SQL, Cloud) alliée à une collaboration interdisciplinaire.
- Prochaines étapes de votre session :
 - ▣ Programmation : apprendre à automatiser les flux de données.
 - ▣ Introduction au Cloud : explorer les infrastructures modernes (AWS, Azure).
 - ▣ Analyse et conception : approfondir la modélisation des bases de données.
- Votre parcours commence avec cette première session :
 - ▣ Vous avez maintenant la carte globale du métier pour donner du sens à vos futurs apprentissages.

Le voyage de la donnée : de la source à la décision

34

- La donnée traverse plusieurs états avant de devenir utile à l'organisation :
 - ▣ Sources de données : captation brute depuis des capteurs, des sites web ou des transactions.
 - ▣ Collecte et transport : déplacement sécurisé de l'information vers un point central.
 - ▣ Transformation : nettoyage et structuration pour rendre la donnée exploitable.
 - ▣ Stockage : organisation dans des bases de données persistantes et cohérentes.
 - ▣ Exploitation : analyse et visualisation pour la prise de décision.
- L'importance de la fluidité :
 - ▣ Une donnée bloquée ou erronée à une étape rend toute la solution inefficace.
 - ▣ Le spécialiste veille à ce que ce voyage soit automatisé et sécurisé.

Le processus ETL : Extraire, Transformer et Charger

35

- L'ETL est la méthode principale pour intégrer des données dans une solution :
 - ▣ Extraction : récupération des données brutes depuis différentes sources (fichiers, bases de données, API).
 - ▣ Transformation : nettoyage, filtrage et formatage des données pour assurer leur cohérence et leur qualité.
 - ▣ Chargement (Load) : insertion des données transformées dans le système de destination pour le stockage final.
- L'objectif de l'ETL :
 - ▣ Centraliser l'information pour faciliter l'analyse globale.
 - ▣ Garantir que les données stockées sont prêtes à être utilisées par les outils de BI (Business Intelligence).
 - ▣ Automatiser les flux pour réduire les interventions manuelles et les erreurs.

Le processus ETL : Extraire, Transformer et Charger

36


- L'ETL est la méthode principale pour intégrer des données dans une solution :
 - ▣ Extraction : récupération des données brutes depuis différentes sources (fichiers, bases de données, API).
 - ▣ Transformation : nettoyage, filtrage et formatage des données pour assurer leur cohérence et leur qualité.
 - ▣ Chargement (Load) : insertion des données transformées dans le système de destination pour le stockage final.
- L'objectif de l'ETL :
 - ▣ Centraliser l'information pour faciliter l'analyse globale.
 - ▣ Garantir que les données stockées sont prêtes à être utilisées par les outils de BI (Business Intelligence).
 - ▣ Automatiser les flux pour réduire les interventions manuelles et les erreurs.

L'Extraction : Récupérer la matière première

- C'est l'étape où l'on se connecte aux différentes sources pour extraire les données brutes. C'est le point d'entrée de tout le système.
- D'où vient la donnée ? (Les Sources)
 - ▣ Bases de données : Systèmes internes (ventes, inventaire, RH).
 - ▣ Fichiers plats : Documents Excel, CSV, fichiers texte.
 - ▣ API : Données provenant d'internet ou de services externes (météo, réseaux sociaux, services de paiement).
 - ▣ Capteurs (IoT) : Données en provenance de machines ou d'objets connectés.
- Les défis du Spécialiste :
 - ▣ Connectivité : Savoir parler "différents langages" pour se brancher à chaque source.
 - ▣ Fréquence : Doit-on extraire les données une fois par jour (Batch) ou dès qu'elles arrivent (Temps réel/Streaming) ?
 - ▣ Volume : Extraire uniquement ce qui est nécessaire pour ne pas ralentir les systèmes sources.

L'Extraction : Récupérer la matière première

- Le résultat : Des informations brutes sans aucune modification. Il s'agit d'une copie fidèle de ce qui existe.
- Points clés :
 - ▣ C'est l'étape la plus dépendante de facteurs externes, le risque d'échec est très élevé.
 - ▣ Si l'extraction échoue, tout le reste du pipeline s'arrête.



EXTRACT

La Transformation : Nettoyer et structurer


39

- C'est l'étape "intelligente" où l'on manipule les données extraites pour les rendre utiles, cohérentes et prêtes pour l'analyse. C'est ici que l'on garantit la qualité des données.
- Que fait-on concrètement ?
 - Nettoyage : Supprimer les doublons, corriger les erreurs de frappe et gérer les données manquantes (ex: remplacer un champ vide par "Inconnu").
 - Standardisation : Harmoniser les formats (ex: transformer toutes les dates en AAAA-MM-JJ ou convertir les devises en dollars canadiens).
 - Filtrage : Ne garder que les données pertinentes pour l'objectif visé (ex: exclure les transactions annulées).
 - Calculs et Agrégations : Créer de nouvelles informations (ex: calculer la marge à partir du prix d'achat et du prix de vente).
- Les défis du Spécialiste :
 - Règles d'affaires : Comprendre les besoins des utilisateurs pour appliquer les bons calculs.
 - Performance : Effectuer ces transformations rapidement, même sur des millions de lignes.
 - Traçabilité : Garder une trace de chaque modification apportée à la donnée originale.

La Transformation : Nettoyer et structurer

40

- Le résultat : Une fois la transformation terminée, l'information devient structurée, cohérente et exempte d'erreur.
- Points clés :
 - ▣ Garbage in, garbage out. Attention aux entrées de cette étape.
 - ▣ C'est l'étape qui prend le plus de temps dans le processus (60% à 80%).



TRANSFORM

Le Chargement : Stocker pour l'utilisation


41

- C'est l'étape finale où les données, désormais propres et formatées, sont insérées dans le système de destination. C'est ici que la donnée devient officiellement disponible pour les analystes et les décideurs.
- Où charge-t-on les données ? (Les Destinations)
 - Data Warehouse (Entrepôt de données) : Un système optimisé pour l'analyse historique (ex: les ventes des 5 dernières années).
 - Data Lake (Lac de données) : Pour stocker de très grands volumes de données brutes ou semi-structurées.
 - Bases de données d'application : Pour alimenter directement un logiciel ou un site web (ex: mettre à jour les stocks en ligne).
- Les défis du Spécialiste :
 - Intégrité : S'assurer que 100 % des données transformées sont arrivées à destination sans corruption.
 - Volume et Fenêtre de temps : Charger les données rapidement pour qu'elles soient disponibles dès l'ouverture des bureaux (souvent la nuit).
 - Gestion des doublons : Vérifier si l'on doit écraser les anciennes données ou ajouter les nouvelles à la suite.

Le Chargement : Stocker pour l'utilisation

42


- Le résultat : Une fois le chargement terminé, la "matière première" est devenue un "produit fini" prêt à créer de la valeur.
- Points clés :
 - ▣ Est-ce que l'information est disponible au bon moment ?
 - ▣ Est-ce que les droits d'accès à l'information sont définis correctement ?



LOAD

L'ETL : synthèse

- Le concept : C'est le « voyage » sécurisé de la donnée, de sa source brute jusqu'à sa destination stratégique.
 - ▣ Extraction → Connecter & Capter : On récupère la matière première partout où elle dort (Bases, API, Excel).
 - ▣ Transformation → Nettoyer & Valoriser : On élimine le "bruit" et les erreurs pour ne garder que la vérité.
 - ▣ Loading → Stocker & Servir : On livre une donnée prête à l'emploi dans l'entrepôt final.



Sécuriser le voyage : Gouvernance et Conformité

44

- Le transport des données ne doit pas seulement être efficace, il doit être sûr et éthique.
- Les piliers de la protection des données :
 - ▣ Confidentialité : S'assurer que seules les personnes autorisées ont accès aux données (gestion des accès).
 - ▣ Intégrité : Garantir que la donnée n'est pas altérée ou corrompue durant son voyage (processus ETL robustes).
 - ▣ Disponibilité : Veiller à ce que le système soit fonctionnel au moment où l'organisation en a besoin.
- Le cadre légal et normatif :
 - ▣ Conformité : Respect des lois (comme la Loi 25 au Québec ou le RGPD en Europe) sur la protection des renseignements personnels.
 - ▣ Éthique : Se questionner sur l'usage des données collectées et les biais potentiels.
 - ▣ Le rôle du spécialiste : Il implémente des mécanismes de sécurité (chiffrement, masquage) dès la conception de la solution pour protéger l'organisation contre les fuites de données.



Scénario : Système de fidélité

45

- Une chaîne d'épicerie veut offrir des coupons de réduction personnalisés sur mobile dès qu'un client passe à la caisse.
- Votre mission en équipe :
 1. Identifier les sources : D'où vient l'info ? (Caisse, application mobile, base de données clients).
 2. Définir l'ETL : Quelles transformations sont nécessaires ? (Calculer le total, vérifier les points de fidélité, filtrer les produits en promotion).
 3. Choisir le stockage : Où garde-t-on l'historique ? (Base de données SQL ou Cloud).
 4. Déterminer l'exploitation : Comment le client reçoit-il l'offre ? (Notification push, courriel).
- Consigne de présentation :
 - Utilisez des boîtes et des flèches pour représenter le mouvement de la donnée.
 - Identifiez un point critique où la sécurité doit être renforcée (ex: protection du nom du client).

Corrigé de l'atelier : Système de fidélité



46

- 1. Flux de la donnée (Architecture simplifiée) :
 - ▣ Sources : Terminaux de point de vente (POS) en magasin + Profil client sur l'App mobile.
 - ▣ ETL (Le moteur) : * Extraction : Récupération du panier d'achat en temps réel.
 - Transformation : Agrégation des achats par catégorie (ex: Fruits, Produits laitiers) et calcul des points.
 - Chargement : Mise à jour du profil dans le Data Warehouse (Cloud).
 - ▣ Exploitation : Algorithme de recommandation qui déclenche une API de notification mobile.
- 2. Le point critique (Sécurité et Gouvernance) :
 - ▣ Données Sensibles : Les numéros de cartes de crédit et les noms doivent être anonymiser avant le stockage pour respecter la Loi 25.
 - ▣ Disponibilité : Le flux doit être "temps réel" : si l'ETL met 2 heures à transformer la donnée, le coupon arrive trop tard !
- 3. Technologies utilisées :
 - ▣ Stockage : SQL pour les transactions, NoSQL pour les préférences clients.
 - ▣ Infrastructures : Serveurs Cloud (Azure/AWS) pour gérer les pics de fréquentation (ex: samedi après-midi).

L'IA et l'automatisation : Révolutionner le métier

47

- L'intelligence artificielle n'est pas une menace, mais un levier de puissance pour le spécialiste.
- Ce qui change concrètement :
 - Automatisation intelligente : L'IA aide à nettoyer les données automatiquement et à détecter des anomalies (erreurs de saisie, fraudes) plus vite qu'un humain.
 - Maintenance prédictive : Capacité d'anticiper une panne de serveur ou une saturation de base de données avant qu'elle ne survienne.
 - Génération de code : Utilisation d'outils (comme les LLM) pour assister l'écriture de requêtes SQL complexes ou de scripts ETL.
- Le nouveau rôle du spécialiste :
 - Il passe de "celui qui déplace les données" à "celui qui supervise les systèmes intelligents".
 - Nécessité de comprendre les modèles d'IA pour bien les alimenter en données de qualité.

Éthique et Vie Privée : La conscience du métier

48

- Avoir accès aux données d'une organisation est un privilège qui vient avec de grandes responsabilités.
- 1. Les biais algorithmiques :
 - ▣ Le problème : Si les données de départ sont incomplètes ou préjugées (ex: historique de crédit biaisé), l'IA reproduira et amplifiera ces erreurs.
 - ▣ Le rôle du spécialiste : S'assurer de la représentativité et de la neutralité des données collectées.
- 2. Protection de la vie privée (Loi 25 / RGPD) :
 - ▣ Confidentialité par défaut : Concevoir des solutions qui protègent l'anonymat (masquage, chiffrement).
 - ▣ Transparence : Savoir expliquer comment et pourquoi une donnée est traitée.
- 3. La sécurité : Un rempart contre les cybermenaces
 - ▣ Le spécialiste doit anticiper les risques de fuites de données qui peuvent ruiner la réputation d'une entreprise.

Synthèse : Le Spécialiste, Maître d'œuvre de la donnée

49

- Ce que vous avez appris :
 - ▣ L'Écosystème : Vous savez distinguer les besoins des PME, des grandes entreprises et du secteur public.
 - ▣ Le Cycle de Vie : Vous comprenez les étapes, de l'analyse des besoins jusqu'à la maintenance.
 - ▣ Le "Voyage" : Vous maîtrisez le concept d'ETL et l'importance de la qualité des données.
 - ▣ La Responsabilité : Vous êtes conscients des enjeux d'éthique, de sécurité et d'IA.
- Pourquoi votre rôle est indispensable :
 - ▣ Sans spécialiste pour structurer, sécuriser et transporter la donnée, l'IA et l'analyse d'affaires ne peuvent pas exister. Vous êtes les bâtisseurs des fondations du monde numérique.



Quiz

50

- Aller sur l'adresse suivante pour le quiz :
 - ▣ <https://gemini.google.com/share/008e9023c26a>
- Ou scanner le QR code suivant :





Atelier : Le marché de l'emploi

51

- Objectif : Comparer les attentes réelles des entreprises avec les rôles et compétences vus en classe.
- Instructions :
 - ▣ Recherche : Trouvez 4 ou 5 offres d'emploi distinctes sur LinkedIn, Indeed, Grenier aux Emplois, Service Québec, ...
 - ▣ Diversité : Essayez de trouver des profils variés (ex: une startup, une grande banque, un ministère, une firme de conseil).
 - ▣ Synthèse : Remplissez la Grille d'analyse d'offres d'emploi fournie.
 - ▣ Analyse : Quel outil ou langage revient le plus souvent ? Quel rôle semble le plus en demande actuellement ?
- Conseil : Ne vous arrêtez pas au titre du poste (ex: "Data Scientist"), lisez bien les responsabilités pour identifier si c'est en réalité un rôle de Spécialiste de solutions de données.