

INITIATION A LA FONCTION DE TRAVAIL


Les tâches d'un spécialiste de solutions de données vues d'un point de vue cycle de vie

L'évolution des méthodes de travail

2

- Le Modèle en Cascade (Waterfall)
 - ▣ Le pionnier : Inspiré de l'ingénierie civile et de la construction.
 - ▣ Le concept : Chaque étape doit être terminée à 100 % avant de passer à la suivante.
 - ▣ La séquence : Analyse > Conception > Développement > Tests > Déploiement.
- Points forts :
 - ▣ Structure rigide et prévisible.
 - ▣ Documentation exhaustive.
- Points faibles :
 - ▣ Effet "tunnel" : On ne voit le résultat qu'à la toute fin.
 - ▣ Coût de changement énorme : Si le besoin change en cours de route, il faut tout recommencer.

L'évolution des méthodes de travail




L'évolution des méthodes de travail

4

- ❑ Le Modèle en V (Années 80 - 90) : Une symétrie entre la conception et la validation
 - ❑ Amélioration de la Cascade : On ne se contente pas de descendre, on prépare la remontée.
 - ❑ Chaque étape de conception (à gauche) possède son étape de test correspondante (à droite).
- ❑ Le fonctionnement :
 - ❑ Branche descendante : Analyse des besoins > Spécifications > Conception.
 - ❑ Pointe du V : La réalisation (le codage/développement).
 - ❑ Branche montante : Tests unitaires > Tests d'intégration > Tests d'acceptation.
- ❑ Points forts :
 - ❑ Met l'accent sur la qualité dès le début du projet.
 - ❑ Moins de risques d'erreurs majeures lors de la livraison finale.
- ❑ Points faibles :
 - ❑ Reste linéaire : Difficile de revenir en arrière sans tout chambouler.
 - ❑ Le client ne voit toujours le produit qu'à la fin de la branche montante.


L'évolution des méthodes de travail



L'évolution des méthodes de travail

- Le Modèle en W (La double vérification)
 - ▣ Le concept : Ne plus attendre le code pour tester
 - ▣ C'est une extension du modèle en V.
 - ▣ On ajoute une deuxième ligne de front : la validation des documents et des concepts.
- Le point fort : La Maquette
 - ▣ Avant de toucher à une base de données réelle, on crée une maquette (structure visuelle ou logique).
 - ▣ On valide le "plan" avec le client pour s'assurer que l'on a bien compris son besoin.
- Pourquoi le "W" ?
 - ▣ Premier V : Le cycle de développement (comme le modèle en V classique).
 - ▣ Deuxième V : Le cycle de vérification des livrables (vérifier les analyses, vérifier les architectures).
- Avantages :
 - ▣ Détection ultra-précoce des erreurs (coûte beaucoup moins cher de corriger un dessin qu'une base de données déjà remplie).
 - ▣ Engagement du client plus élevé grâce aux maquettes.

L'évolution des méthodes de travail



L'évolution des méthodes de travail


- Le Modèle en Spirale (Années 90) :
 - ▣ Le concept : On ne construit pas tout d'un coup
 - ▣ Ce modèle combine l'aspect répétitif de l'itération avec les contrôles du modèle en Cascade.
 - ▣ On avance par cycles (spiralettes). À chaque tour, le projet gagne en précision.
- Les 4 quadrants de chaque cycle :
 - ▣ Déterminer les objectifs : Qu'est-ce qu'on veut accomplir dans ce tour-ci ?
 - ▣ Analyser les risques : C'est le cœur du modèle. Que se passe-t-il si la technologie choisie ne fonctionne pas ?
 - ▣ Développer et tester : On construit un prototype (une version simplifiée).
 - ▣ Planifier le cycle suivant : On valide avec le client et on décide de la suite.
- Points forts :
 - ▣ Idéal pour les projets complexes et innovants.
 - ▣ On identifie les problèmes très tôt grâce aux prototypes.
- Points faibles :
 - ▣ Très coûteux en temps de gestion.
 - ▣ Nécessite une expertise élevée en analyse de risques.

L'évolution des méthodes de travail

Développement itératif

Déterminer les objectifs, les alternatives et les contraintes

Évaluer les alternatives, identifier, résoudre les risques



[Boehm 88]

L'évolution des méthodes de travail

10

- Le Manifeste Agile et Scrum (Années 2000 - Aujourd'hui)
 - ▣ Le concept : Privilégier l'adaptation au plan rigide
 - ▣ On ne livre pas tout à la fin, on livre des morceaux fonctionnels très souvent.
 - ▣ Le projet est découpé en "Sprints" (cycles courts de 2 à 4 semaines).
- Les 4 valeurs fondamentales :
 - ▣ Les individus et leurs interactions plutôt que les processus et les outils.
 - ▣ Des solutions qui fonctionnent plutôt qu'une documentation exhaustive.
 - ▣ La collaboration avec le client plutôt que la négociation contractuelle.
 - ▣ L'adaptation au changement plutôt que le suivi d'un plan.

L'évolution des méthodes de travail


11

- Le Manifeste Agile et Scrum (Années 2000 - Aujourd'hui)
- Pourquoi c'est devenu la norme ?
 - ▣ Visibilité constante : Le client voit l'évolution des données en temps réel.
 - ▣ Réduction du gaspillage : Si une direction n'est pas la bonne, on le sait en 2 semaines, pas en 6 mois.
 - ▣ Moral de l'équipe : On voit le résultat de son travail plus rapidement.
- Points faibles :
 - ▣ Peut être difficile de prévoir le coût final exact et la date de fin précise.
 - ▣ Demande une implication très active du client.

L'évolution des méthodes de travail

12

MÉTHODE SCRUM



Spécificités du projet de données

13

- Pourquoi est-ce différent d'un logiciel classique ?
- 1. Le Code vs La Donnée
 - ▣ Logiciel : Le code est l'élément central (la logique).
 - ▣ Données :
 - Le code est souvent un simple "tuyau" au service de la donnée.
 - Si la donnée change de format à la source, tout le système peut s'arrêter.
- 2. La nature de la matière première
 - ▣ Logiciel : On crée des fonctionnalités à partir de rien (ex: un bouton "Acheter").
 - ▣ Données :
 - On travaille avec une matière existante, parfois imprévisible, incomplète ou sale.
 - On doit composer avec le réel.

Spécificités du projet de données

14

- Pourquoi est-ce différent d'un logiciel classique ?
- 3. Le cycle de vie "Vivante"
 - ▣ Logiciel : Une fois la fonction "Imprimer" livrée et testée, elle change peu.
 - ▣ Données :
 - Les données évoluent chaque seconde.
 - Un flux qui fonctionne aujourd'hui peut échouer demain parce qu'un capteur envoie une valeur aberrante.
- 4. L'importance de l'historique
 - ▣ Logiciel : On se concentre sur l'état actuel de l'application.
 - ▣ Données : On doit souvent conserver et gérer des années d'historique (Big Data) tout en garantissant que les chiffres de 2020 restent comparables à ceux de 2025.



Activité : Le Jeu du Diagnostic

15

- Le Scénario :
 - ▣ Lundi, 8h00 : Le rapport de ventes affiche 0 \$ pour la journée de dimanche.
 - ▣ Pourtant, les caméras montrent des files d'attente dans tous les cafés !
- Les indices à votre disposition (Les pièces à conviction) :
 - ▣ Le Log technique : Le système de transfert de données indique "Erreur 404 : Serveur de la boutique de Montréal introuvable à 23h00".
 - ▣ La base de données : Vous voyez les transactions, mais elles ont toutes le statut "En attente".
 - ▣ Le Cahier de charges : Il est écrit : "Le rapport ne doit afficher que les transactions dont le paiement est complété".
 - ▣ Le Code (ETL) : Le développeur a écrit une règle qui dit : Si Date = Dimanche alors Ventes = 0 (pour un test qu'il a oublié d'effacer).
- Votre mission :
 - ▣ En équipe, associez chaque indice à une erreur humaine ou technique liée à une étape du cycle de vie (Analyse, Conception, Développement, Tests ou Exploitation).



Activité : Le Jeu du Diagnostic

16

- Hypothèse 1 : "C'est un problème de câbles ou de réseau" (Indice 1)
 - ▣ Diagnostic : Étape d'Exploitation / Maintenance.
 - ▣ Explication : Le spécialiste doit s'assurer que les "tuyaux" entre les boutiques et le serveur central fonctionnent. Si le serveur tombe, la donnée ne voyage plus.
- Hypothèse 2 : "Le rapport ne regarde pas la bonne chose" (Indice 3)
 - ▣ Diagnostic : Étape d'Analyse des besoins.
 - ▣ Explication : Si le client a demandé de ne voir que les paiements "complétés", mais que le système de carte de crédit prend 24h pour valider, le dimanche affichera toujours 0 le lundi matin. Ce n'est pas un bug technique, c'est une mauvaise définition au départ.



Activité : Le Jeu du Diagnostic

17

- Hypothèse 3 : "C'est une erreur de calcul" (Indice 4)
 - ▣ Diagnostic : Étape de Développement.
 - ▣ Explication : C'est l'erreur classique du "copier-coller" ou du test oublié. Le spécialiste a codé une règle qui écrase la réalité.
- Hypothèse 4 : "On a oublié de tester le cas du dimanche" (Indice 2)
 - ▣ Diagnostic : Étape de Tests / Validation.
 - ▣ Explication : Le système garde les ventes "en attente". Si on avait testé le cycle complet un dimanche avant de lancer le projet, on aurait vu que le statut ne changeait pas assez vite.

L'équipe de projet

18

- La collaboration au cœur de la donnée :
 - ▣ Le constat : Une solution de données est trop complexe pour une seule personne.
 - ▣ C'est un sport d'équipe où chacun possède une pièce du casse-tête.
- Les trois grands pôles de collaboration :
 - ▣ Le pôle "Affaires" (Le BESOIN) :
 - Qui : Chef de projet, Analyste d'affaires (BA).
 - Leur rôle : Définir les objectifs et le budget.
 - ▣ Le pôle "Technique" (La CONSTRUCTION) :
 - Qui : Architecte, Spécialiste de solutions de données, Développeur.
 - Leur rôle : Bâtir les tuyaux, les bases de données et les applications.
 - ▣ Le pôle "Qualité et Utilisation" (La VALEUR) :
 - Qui : Testeur (QA), Analyste de données (Data Analyst), Utilisateurs finaux.
 - Leur rôle : Vérifier que tout fonctionne et tirer des conclusions des chiffres.

L'Amont – Analyse et Recueil des besoins

19

Comprendre avant de construire

□ Les tâches du spécialiste :

- ▣ L'écoute active : Rencontrer les utilisateurs pour comprendre leurs problèmes (ex: "Mes rapports prennent 10 minutes à charger").
- ▣ L'inventaire des sources : Identifier où se trouve l'information. Est-ce un fichier Excel ? Une base de données ? Un capteur ?
- ▣ L'évaluation de la qualité : Vérifier si les données sont fiables. Si 30 % des adresses courriels sont manquantes, on doit le signaler tout de suite.

□ Le défi majeur :

- ▣ Les utilisateurs parlent en termes de "Métier" (ventes, clients, profits).
- ▣ Le spécialiste pense en termes de "Technique" (types de données, clés primaires, jointures).
- ▣ L'enjeu : Une mauvaise analyse ici entraîne une solution inutile, même si le code est parfait.

De l'Analyse à la Conception

20

Transformer le "Besoin" en "Plan de construction"

- La phase d'Analyse (Le "Quoi")
 - ▣ Objectif : Écouter et documenter.
 - ▣ Résultat : On sait que le client veut suivre ses ventes par région pour identifier ses meilleurs vendeurs.
 - ▣ *On ne parle pas encore de technologie ici.*
- La phase de Conception (Le "Comment")
 - ▣ Objectif : Imaginer la structure technique qui répondra au besoin.
 - ▣ Le travail du spécialiste :
 - Choisir le type de stockage (Relationnel ? Cloud ?).
 - Définir comment les données vont circuler (Architecture des flux).
 - Créer les plans détaillés (Les livrables : Schémas et Dictionnaire).

Les livrables de la conception

21

Le Dictionnaire et le Schéma

- Le Dictionnaire de données (Le "Quoi")
 - ▣ C'est une liste exhaustive de chaque donnée utilisée dans le projet.
 - ▣ Ce qu'on y trouve : Nom du champ (ex: prix_unitaire), type (ex: nombre décimal), description (ex: "Prix avant taxes en CAD") et règles (ex: "Doit être supérieur à 0").
 - ▣ Utilité : S'assurer que tout le monde parle le même langage.
- Le Schéma Conceptuel (Le "Comment")
 - ▣ C'est la carte géographique de votre base de données.
 - ▣ Le concept : On dessine des boîtes (les Entités) et des traits (les Relations).
 - ▣ Exemple : Une boîte [CLIENT] est liée à une boîte [COMMANDE].
 - ▣ Utilité : Visualiser la structure globale avant de commencer à programmer.
- Le saviez-vous ?
 - ▣ Une erreur de conception sur un schéma coûte 10 fois moins cher à corriger qu'une erreur découverte une fois que la base de données est remplie de millions de lignes.

Les livrables de la conception

22

- Le Dictionnaire de données (La précision)
 - ▣ C'est le "répertoire" officiel de toutes les informations du projet.
 - ▣ Ce qu'on y trouve :
 - Le nom technique (ex: date_transaction).
 - Le type (ex: Date, Texte, Nombre).
 - La description (ex: "Date de l'achat en format AAAA-MM-JJ").
 - La règle (ex: "Ne peut pas être une date dans le futur").
 - ▣ Utilité :
 - Éviter que deux personnes utilisent le même mot pour deux choses différentes.
 - Disposer d'un référentiel unique disponible en tout temps pour tous les membre du projet.

Les livrables de la conception

23

□ Le Schéma Conceptuel (La vision d'ensemble)

- C'est une représentation visuelle (graphique) de la base de données.
- Le concept :
 - On dessine des boîtes pour les objets (Clients, Produits, Ventes) et des flèches pour les liens entre eux.
 - On représente le type de lien entre les objets.
 - On associe des propriétés à chaque objet.
- Exemple :
 - Un [CLIENT] possède plusieurs [COMMANDES].
 - Une commande n'appartient qu'à un seul client.
 - Un client doit être défini avec un nom, une adresse, un numéro de téléphone, ...
- Utilité :
 - Valider que la structure peut répondre aux questions posées lors de l'analyse.

L'analyse et la conception

24

□ Pourquoi ces deux phases sont importantes ?

▣ L'efficacité :

- Si vous sautez l'Analyse, vous construisez quelque chose d'inutile.
- Si vous sautez la Conception, vous construisez quelque chose de fragile qui va s'écrouler à la première modification.

▣ Le coût de l'erreur :

- Modifier un schéma avec une souris prend 30 secondes.
- Modifier une base de données en production avec des millions de lignes peut prendre des jours et coûter des milliers de dollars.

▣ Le ratio du succès :

- Ne faites pas l'erreur de commencer à coder dès que le client a fini de parler.
- Dans les métiers de la donnée on passe souvent 30% du temps en analyse/conception avant même d'écrire une seule ligne de code.



Activité : L'Interprète (Analyse)

25

- Le contexte :
 - ▣ Le propriétaire d'une chaîne de gymnases vous rencontre.
 - ▣ Il est frustré : « Je veux savoir qui sont mes meilleurs clients pour leur offrir une promotion, mais mon système actuel ne me dit rien ! »
- Votre mission en équipes de 2 ou 3 :
 - ▣ Posez les 3 bonnes questions d'analyse pour transformer cette plainte en besoins de données précis.
 - ▣ Répondez aux questions en imaginant un contexte précis.
 - ▣ Préparez un petit dictionnaire de données qui couvre les réponses proposées.



Activité : L'Interprète (Analyse)

26

- Exemples de questions :
 - ▣ C'est quoi un "meilleur" client ?
 - Celui qui paie le plus cher ?
 - Celui qui vient le plus souvent ?
 - Celui qui amène d'autres clients ?
 - ...
 - ▣ De quelles informations avons-nous besoin sur lui ?
 - Montants dépensés.
 - Nombre de visites par année / par mois.
 - Nombre de clients parrainés.
 - Courriel / Téléphone
 - ▣ Où se trouve l'information actuellement ?
 - Bases de données
 - Documents papier
 - ...



Activité : L'Interprète (Analyse)

27

- Structure d'un dictionnaire de données :

Nom du champ (Technique)	Type de donnée	Description / Règle
id_membre	Nombre	Identifiant unique du membre
?	?	?
?	?	?
?	?	?


La Réalisation – Construire la solution

28

- Le développement des "tuyaux" de données (ETL) :
 - ▣ Le concept central : L'ETL Le travail technique consiste majoritairement à créer des flux de données. On utilise souvent l'acronyme ETL :
 - Extract (Extraire) : Aller chercher la donnée là où elle dort (Excel, SQL, Cloud, Web).
 - Transform (Transformer) : Nettoyer et calculer. C'est ici qu'on applique les règles (ex: convertir les prix US en CAD).
 - Load (Charger) : Ranger la donnée propre dans sa nouvelle maison (le "Data Warehouse" ou "Entrepôt de données").
 - ▣ Le rôle du spécialiste :
 - Écrire des scripts (SQL, Python) ou utiliser des outils visuels.
 - S'assurer que le flux est automatisé : il doit pouvoir rouler chaque nuit sans intervention humaine.
 - Gérer les erreurs : que fait le système si le fichier source est vide ?

La Réalisation – Construire la solution

29



La Réalisation – La rigueur des Tests

30

- On ne livre jamais sans vérifier :
 - ▣ Pourquoi tester en données est différent ?
 - En logiciel, on teste si le bouton marche.
 - En données, on teste si le chiffre est vrai.
 - ▣ Les 4 niveaux de tests indispensables :
 - Tests Unitaires :
 - Est-ce que ma transformation mathématique est juste sur une seule ligne ?
 - Tests d'Intégration :
 - Est-ce que mon flux arrive à se connecter à la base de données du client sans planter ?
 - Tests de Qualité de Donnée (Data Quality) :
 - Exemple : Est-ce que j'ai des doublons ?
 - Est-ce que des champs obligatoires sont vides ?
 - Tests de Validité (Le gros bon sens) :
 - Est-ce que la donnée respecte des limites logiques ?
 - Exemple : Une température humaine ne peut pas être de 150°C.



Activité : La Chasse aux Anomalies

31

- Le Scénario :
 - ▣ Vous avez développé un flux (ETL) pour calculer la commission des vendeurs (5 % des ventes).
 - ▣ Votre code est techniquement parfait : il tourne sans erreur.
- Le Problème :
 - ▣ Le comptable vous appelle, furieux : « Le vendeur "Jean" reçoit une commission de 50000\$ pour hier, alors qu'il n'a vendu que 3 cafés ! »
- Votre mission :
 - ▣ Regardez cet échantillon de données sources.
 - ▣ Trouvez l'intrus et dites quel test de qualité a manqué à votre solution.

Activité : La Chasse aux Anomalies



32

□ Échantillon de données :

ID_Vente	Nom_Vendeur	Produit	Quantité	Prix_Unitaire	Total_Ligne
101	Jean	Café Latte	2	4.50	9.00
102	Jean	Espresso	1	3.50	3.50
103	Jean	Muffin	1	999999.00	999999.00
104	Sophie	Thé Vert	1	3.00	3.00



Activité : La Chasse aux Anomalies

33

- Identification du problème :
 - ▣ Pourquoi le code n'a rien dit ?
 - ▣ Parce que 999999×0.05 est un calcul mathématique valide.
 - ▣ La machine "obéit", elle ne "réfléchit" pas.
- Comment l'éviter ?
 - ▣ C'est ici qu'on introduit les Tests de Validité.
 - ▣ On aurait dû coder une règle : "Si Prix_Unitaire > 20 \$, bloquer la ligne et envoyer une alerte".
- Leçon à retenir :
 - ▣ Un développeur de données doit toujours se demander : Quelles sont les limites raisonnables de mes chiffres ?

Déploiement et Mise en production

34

□ Le passage du "Projet" à la "Réalité" :

▣ Le Déploiement :

- C'est l'installation finale de la solution sur les serveurs de l'entreprise (ou dans le Cloud).
- L'enjeu : Ne pas briser ce qui existe déjà ! On fait souvent une "mise en prod" la nuit ou le week-end pour éviter de bloquer les utilisateurs.

▣ La Documentation (Indispensable) :

- Guide utilisateur : Comment lire le rapport ?
- Guide technique : Comment relancer le flux si le serveur tombe ?
- Un projet sans doc est un projet condamné à mourir au premier bug.

▣ La Formation :

- Accompagner les utilisateurs pour qu'ils s'approprient l'outil. S'ils ne comprennent pas le tableau de bord, ils ne l'utiliseront pas.

Maintenance et Évolution

35

- Un projet de données ne dort jamais :
 - ▣ La Maintenance (Le SAV) :
 - Corrective : Réparer ce qui casse (ex: une source de données change de format).
 - Préventive : Surveiller les serveurs avant qu'ils ne soient pleins.
 - ▣ L'Évolution (La vie du projet) :
 - Une fois que le client a son rapport, il en veut souvent plus !
 - On repart alors dans un mini-cycle : Analyse d'un nouveau besoin > Conception > Développement > Tests > Déploiement.
- Pourquoi c'est important ?
 - ▣ Dans le monde de la donnée, les systèmes s'usent plus vite qu'en logiciel classique car la "matière première" (la donnée) change constamment de volume et de forme.

Synthèse : Le Voyage de la Donnée

36

Phase	Objectif Clé	Votre rôle principal
1. Amont (Analyse)	Comprendre le "Quoi"	L'Interprète : Traduire le besoin métier en besoins techniques.
2. Conception	Planifier le "Comment"	L'Architecte : Créer les schémas et le dictionnaire (les plans).
3. Réalisation	Construire et Valider	Le Plombier & Le Détective : Créer les flux (ETL) et chasser les anomalies.
4. Aval (Déploiement)	Livrer et Maintenir	Le Gardien : Mettre en service, documenter et faire évoluer.



Quiz

37

- Aller sur l'adresse suivante pour le quiz :
 - ▣ <https://gemini.google.com/share/642156c9bb92>
- Ou scanner le QR code suivant :

