

# Test Statistiques Descriptives - Test 1

**Sujet:** Statistiques Descriptives

**Niveau:** Intermédiaire

**Nombre de questions:** 25

---

## Questions et Réponses

**Q1.** Quelles sont les quatre échelles de mesure et donnez un exemple bancaire pour chacune?

**R1.** | Échelle | Caractéristique | Exemple Bancaire | |----|-----|-----| | **Nominale** | Catégories sans ordre | Type de compte (épargne, courant) | | **Ordinale** | Catégories ordonnées | Rating crédit (A, B, C, D) | | **Intervalle** | Distances égales, pas de zéro absolu | Score de crédit (300-850) | | **Ratio** | Zéro absolu significatif | Montant du prêt (0 = pas de prêt) |

---

**Q2.** Quelle est la différence entre moyenne, médiane et mode? Quand utiliser chacun?

**R2.** | Mesure | Définition | Quand utiliser | |----|-----|-----| | **Moyenne** |  $\sum x_i/n$  | Distribution symétrique, pas d'outliers | | **Médiane** | Valeur centrale | Distribution asymétrique, outliers | | **Mode** | Valeur la plus fréquente | Données catégorielles, multimodales |

**Exemple:** Pour les salaires (distribution asymétrique), la médiane est préférable.

---

**Q3.** Calculez la moyenne, médiane et mode pour: [5, 7, 8, 8, 10, 12, 15, 45]

**R3.** - **Moyenne:**  $(5+7+8+8+10+12+15+45)/8 = 110/8 = 13.75$  - **Médiane:** 8 valeurs → moyenne des 4ème et 5ème =  $(8+10)/2 = 9$  - **Mode:** 8 (apparaît 2 fois)

**Observation:** La moyenne (13.75) est tirée vers le haut par l'outlier (45). La médiane (9) est plus représentative.

---

**Q4.** Qu'est-ce que la variance et l'écart-type? Donnez les formules.

**R4. Variance (échantillon):**

$$s^2 = \frac{\sum (x - \bar{x})^2}{(n-1)}$$

**Écart-type:**

$$s = \sqrt{s^2} = \sqrt{\frac{\sum (x - \bar{x})^2}{(n-1)}}$$

**Interprétation:** Mesure la dispersion des données autour de la moyenne. - Écart-type faible → données concentrées - Écart-type élevé → données dispersées

---

**Q5.** Pourquoi divise-t-on par (n-1) et non par n pour l'écart-type échantillonnal?

**R5.** C'est la **correction de Bessel** pour obtenir un estimateur non biaisé de la variance de la population.

- Avec n: On sous-estime la variance (biased)
- Avec (n-1): Estimateur non biaisé (unbiased)

**Explication:** On perd un degré de liberté car on utilise  $\bar{x}$  (calculé à partir des mêmes données) comme référence.

---

**Q6.** Qu'est-ce que le coefficient de variation (CV) et comment l'interpréter?

**R6. Formule:**

$$CV = (s / \bar{x}) \times 100\%$$

**Interprétation:** -  $CV < 15\%$ : Faible variabilité (données homogènes) -  $15\% < CV < 30\%$ : Variabilité modérée -  $CV > 30\%$ : Forte variabilité (données hétérogènes)

**Avantage:** Permet de comparer la variabilité entre variables de différentes échelles.

---

**Q7.** Définissez les quartiles Q1, Q2, Q3 et l'IQR.

**R7. - Q1 (25ème percentile):** 25% des données sont en dessous - **Q2 (50ème percentile):** Médiane, 50% en dessous - **Q3 (75ème percentile):** 75% des données sont en dessous - **IQR (Interquartile Range):** Q3 - Q1

**Utilisation:** L'IQR mesure la dispersion de la moitié centrale des données, robuste aux outliers.

---

**Q8.** Calculez Q1, Q2, Q3 et IQR pour: [2, 4, 6, 8, 10, 12, 14, 16]

**R8.** Données ordonnées: 2, 4, 6, 8, 10, 12, 14, 16 (n=8)

- **Q1:** Médiane de [2, 4, 6, 8] =  $(4+6)/2 = 5$
  - **Q2:** Médiane totale =  $(8+10)/2 = 9$
  - **Q3:** Médiane de [10, 12, 14, 16] =  $(12+14)/2 = 13$
  - **IQR:** Q3 - Q1 =  $13 - 5 = 8$
- 

**Q9.** Comment utiliser l'IQR pour détecter les outliers?

**R9. Règle des 1.5 IQR:**

$$\text{Borne inférieure} = Q1 - 1.5 \times \text{IQR}$$

$$\text{Borne supérieure} = Q3 + 1.5 \times \text{IQR}$$

Toute valeur hors de ces bornes est considérée comme outlier.

**Exemple:** Si Q1=5, Q3=13, IQR=8: - Borne inf:  $5 - 1.5 \times 8 = -7$  - Borne sup:  $13 + 1.5 \times 8 = 25$   
- Outliers:  $x < -7$  ou  $x > 25$

---

**Q10.** Qu'est-ce que le skewness (asymétrie) et comment l'interpréter?

**R10.** Le **skewness** mesure l'asymétrie de la distribution.

**Interprétation:** - **Skew = 0:** Distribution symétrique (moyenne  $\approx$  médiane) - **Skew > 0:** Asymétrie positive (queue à droite, moyenne > médiane) - **Skew < 0:** Asymétrie négative (queue à gauche, moyenne < médiane)

**Règle pratique:** -  $|\text{skew}| < 0.5$ : Approximativement symétrique -  $0.5 < |\text{skew}| < 1$ : Modérément asymétrique -  $|\text{skew}| > 1$ : Fortement asymétrique

---

**Q11.** Qu'est-ce que le kurtosis et comment l'interpréter?

**R11.** Le **kurtosis** mesure l' "épaisseur" des queues de la distribution.

**Kurtosis excédentaire (par rapport à la normale):** - **Kurt = 0:** Mésokurtique (comme la normale) - **Kurt > 0:** Leptokurtique (queues lourdes, plus de valeurs extrêmes) - **Kurt < 0:** Platykurtique (queues légères, moins de valeurs extrêmes)

**Impact bancaire:** Un kurtosis élevé sur les pertes indique plus d'événements extrêmes.

---

**Q12.** Comment construire un tableau de fréquences?

**R12.**

```
# Fréquence absolue
freq_abs = df['categorie'].value_counts()

# Fréquence relative
freq_rel = df['categorie'].value_counts(normalize=True)

# Tableau complet
freq_table = pd.DataFrame({
    'Fréquence': freq_abs,
    'Pourcentage': freq_rel * 100,
    'Cumul': freq_rel.cumsum() * 100
})
```

---

**Q13.** Qu'est-ce qu'un tableau de contingence et à quoi sert-il?

**R13.** Un **tableau de contingence** (crosstab) montre la distribution jointe de deux variables catégorielles.

```
contingency = pd.crosstab(df['secteur'], df['defaut'], margins=True)
```

**Utilisation:** - Analyser la relation entre deux variables catégorielles - Base pour le test du Chi-carré - Calculer des probabilités conditionnelles

---

**Q14.** Comment calculer les percentiles en Python?

**R14.**

```
import numpy as np

# Percentile unique
p90 = np.percentile(df['montant'], 90)

# Plusieurs percentiles
percentiles = np.percentile(df['montant'], [10, 25, 50, 75, 90])

# Avec Pandas
df['montant'].quantile([0.1, 0.25, 0.5, 0.75, 0.9])

# Rank en percentile
df['percentile_rank'] = df['montant'].rank(pct=True) * 100
```

---

**Q15.** Quelle est la relation entre moyenne, médiane et mode selon la forme de la distribution?

**R15.** | Distribution | Relation | |-----|-----| | **Symétrique** | Mode  $\approx$  Médiane  $\approx$  Moyenne  
| | **Asymétrique droite** | Mode < Médiane < Moyenne | | **Asymétrique gauche** | Moyenne < Médiane < Mode |

**Règle empirique (distribution unimodale):**

Moyenne - Mode  $\approx 3 \times$  (Moyenne - Médiane)

---

**Q16.** Comment calculer la moyenne pondérée?

**R16. Formule:**

$\bar{x} = \frac{\sum(w \times x)}{\sum w}$

**Exemple bancaire:** Taux moyen pondéré par montant

```
# Méthode 1: np.average
weighted_mean = np.average(df['taux'], weights=df['montant'])

# Méthode 2: calcul manuel
weighted_mean = (df['taux'] * df['montant']).sum() / df['montant'].sum()
```

---

**Q17.** Qu'est-ce que l'étendue (range) et quelles sont ses limites?

**R17. Formule:**

Étendue = Max - Min

**Limites:** - Très sensible aux outliers - N'utilise que 2 valeurs - Ne donne pas d'information sur la distribution - Peut augmenter avec la taille de l'échantillon

**Alternative robuste:** IQR (Interquartile Range)

---

**Q18.** Comment interpréter la moyenne et l'écart-type avec la règle empirique (68-95-99.7)?

**R18.** Pour une distribution **normale**: -  $\sim 68\%$  des données sont dans  $[\mu - \sigma, \mu + \sigma]$  -  $\sim 95\%$  des données sont dans  $[\mu - 2\sigma, \mu + 2\sigma]$  -  $\sim 99.7\%$  des données sont dans  $[\mu - 3\sigma, \mu + 3\sigma]$

**Application bancaire:** Si le montant moyen de prêt = 100K avec  $\sigma = 20K$ : - 68% des prêts entre 80K et 120K - 95% entre 60K et 140K - 99.7% entre 40K et 160K

---

**Q19.** Comment calculer les statistiques descriptives par groupe?

**R19.**

```
# Par groupe unique
df.groupby('agence')['montant'].describe()

# Statistiques personnalisées
stats = df.groupby('agence')['montant'].agg([
    'count',
    'mean',
    'median',
    'std',
    ('cv', lambda x: x.std() / x.mean() * 100),
])
```

```
( 'skew', 'skew' )
])
```

---

**Q20.** Qu'est-ce que la covariance et comment l'interpréter?

**R20. Formule:**

$$\text{Cov}(X,Y) = \frac{\sum (x - \bar{x})(y - \bar{y})}{(n-1)}$$

**Interprétation:** - **Cov > 0:** Relation positive (X ↑ quand Y ↑) - **Cov < 0:** Relation négative (X ↓ quand Y ↑) - **Cov ≈ 0:** Pas de relation linéaire

**Limite:** Dépend des unités, pas comparable entre variables.

---

**Q21.** Quelle est la différence entre covariance et corrélation?

**R21.** || Covariance | Corrélation | |—|—|—|—|—|—|—| | **Formule** |  $\text{Cov}(X,Y)$  |  $\text{Cov}(X,Y) / (s_x \times s_y)$   
 || **Plage** |  $-\infty$  à  $+\infty$  |  $-1$  à  $+1$  || **Unités** | Dépend des variables | Sans unité || **Interprétation**  
 | Difficile | Facile || **Comparabilité** | Non | Oui |

**Corrélation = Covariance standardisée**

---

**Q22.** Comment calculer et interpréter le coefficient de corrélation de Pearson?

**R22.**

```
# Calcul
correlation = df['score_credit'].corr(df['montant'])
# ou
correlation = np.corrcoef(df['score_credit'], df['montant'])[0,1]
```

**Interprétation:** - **|r| > 0.7:** Forte corrélation - **0.3 < |r| < 0.7:** Corrélation modérée - **|r| < 0.3:** Faible corrélation

**Attention:** Mesure uniquement les relations LINÉAIRES.

---

**Q23.** Quelles sont les mesures robustes aux outliers?

**R23.** | Mesure Standard | Alternative Robuste | |—|—|—|—|—|—|—| | Moyenne | **Médiane** | | Écart-type | **IQR** ou **MAD** | | Range | **IQR** | | Corrélation Pearson | **Spearman** |

**MAD (Median Absolute Deviation):**

$$\text{MAD} = \text{median}(|x - \text{median}(x)|)$$


---

**Q24.** Comment présenter un résumé statistique complet (five-number summary)?

**R24.** Le **five-number summary:** 1. **Minimum** 2. **Q1 (25ème percentile)** 3. **Médiane (Q2)** 4. **Q3 (75ème percentile)** 5. **Maximum**

```
df['montant'].describe()

# Manuel
summary = {
    'min': df['montant'].min(),
    'Q1': df['montant'].quantile(0.25),
```

```

'median': df['montant'].median(),
'Q3': df['montant'].quantile(0.75),
'max': df['montant'].max()
}

```

---

**Q25.** Analysez les statistiques suivantes et donnez vos conclusions: - Montant moyen: 85,000 HTG - Montant médian: 52,000 HTG - Écart-type: 95,000 HTG - Skewness: 2.3 - Kurtosis: 8.1

**R25. Analyse:** 1. **Moyenne » Médiane (85K vs 52K):** Asymétrie droite confirmée 2. **Skewness = 2.3:** Fortement asymétrique positif 3. **CV = 95/85 = 112%:** Très forte variabilité 4. **Kurtosis = 8.1:** Queues très lourdes, valeurs extrêmes

**Conclusions:** - Distribution très asymétrique avec outliers élevés - **Utiliser la médiane** (52K) comme mesure de tendance centrale - **Utiliser l'IQR** pour la dispersion - Présence probable de quelques très gros prêts - Envisager une **transformation log** pour l'analyse

---

## Scoring

Score	Niveau
0-10	À améliorer
11-17	Intermédiaire
18-22	Avancé
23-25	Expert